

GEMA: Gemelo Digital Metabólico con Aprendizaje Automático para la Detección Temprana del Síndrome Metabólico en el Contexto Peruano

León Sánchez Fransua Mijail, Escudero Díaz Alessandro Leonardo,
Mejía Urbina Cristian Leonel, Carhuamaca Rivera Stefany Miluska

Facultad de Ingeniería Industrial y de Sistemas
Universidad Nacional de Ingeniería — Lima, Perú

fransua.leon.s@uni.pe alessandro.escudero.d@uni.pe
cristian.mejia.u@uni.pe stefany.carhuamaca.r@uni.pe

Resumen—En el Perú casi nueve de cada diez adultos cargan con alguna alteración metabólica, pero el síndrome metabólico avanza en silencio porque no se detecta a tiempo ni se hace seguimiento: conseguir una cita con un especialista del MINSA puede tomar entre dos y seis meses, y tratar una diabetes ya declarada le cuesta al Estado entre S/3 500 y S/8 000 al año por paciente. Presentamos GEMA, un gemelo digital que reconstruye el comportamiento metabólico de cada persona a partir de un sensor continuo de glucosa, un reloj inteligente y lo que la persona registra a diario, y resume ese estado en un Índice de Carga Metabólica (ICM, 0–100) que da vida a un avatar. El motor de inteligencia son dos modelos de aprendizaje automático entrenados con una población sintética construida sobre relaciones fisiológicas publicadas: un clasificador de riesgo (Random Forest) con 88,5 % de exactitud (validación cruzada de 87,5 % $\pm$ 0,9 %) y un predictor del pico glucémico postprandial (Gradient Boosting) con un error de 6,3 mg/dL ($R^2 = 0,91$). Ambos superan las metas que nos fijó la guía técnica del proyecto (>85 % y <15 mg/dL). Sobre el predictor montamos un simulador de escenarios “¿qué pasaría si...?” del que salen recomendaciones concretas y medibles. Todo esto se entrega en un MVP funcional de 14 pantallas. La motivación de fondo es simple: no existe todavía un gemelo metabólico pensado para la dieta y el perfil del adulto peruano.

Palabras clave—gemelo digital, síndrome metabólico, aprendizaje automático, Random Forest, Gradient Boosting, predicción glucémica, salud digital, Perú.

I. INTRODUCCIÓN

El síndrome metabólico es la antesala de buena parte de la carga de enfermedad crónica del país. Reúne varias alteraciones que suelen aparecer juntas —obesidad abdominal, glucosa elevada, triglicéridos altos, HDL bajo e hipertensión— y que comparten una raíz común: la resistencia a la insulina. Se diagnostica cuando se cumplen al menos tres de los cinco criterios de la Tabla I [1]. Lo que vuelve peligrosa a esta condición no es ninguno de esos criterios por separado, sino que durante años no produce síntoma alguno. Para cuando la persona siente algo, el daño ya está hecho: el camino habitual va de la alteración silenciosa a la prediabetes, de ahí a la diabetes tipo 2 y, finalmente, a la enfermedad cardiovascular o renal.

El sistema de salud actual llega tarde a este problema por tres razones que identificamos al estudiar el contexto. La primera es el tiempo de espera: en el MINSA, ver a un especialista puede demorar entre dos y seis meses, y la enfermedad no espera. La segunda es la falta de

TABLA I
COMPONENTES DIAGNÓSTICOS DEL SÍNDROME METABÓLICO (A LA VEZ, INPUTS DEL GEMELO)

Componente	Umbral diagnóstico (H/M)
Circunferencia de cintura	≥ 102 / ≥ 88 cm
Triglicéridos	≥ 150 mg/dL
Colesterol HDL	< 40 / < 50 mg/dL
Presión arterial	$\geq 130/85$ mmHg
Glucosa en ayunas	≥ 100 mg/dL




Fig. 1. Prevalencia del síndrome metabólico en el Perú según población y criterio diagnóstico. La asimetría de género y los picos en poblaciones vulnerables justifican un tamizaje continuo, accesible y de bajo costo.

seguimiento: una vez fuera del consultorio, el paciente queda solo, sin retroalimentación ni alertas, lo que explica las altas tasas de abandono del tratamiento. La tercera es el costo: atender un caso de diabetes ya instalada cuesta entre S/3 500 y S/8 000 anuales por paciente, y las descompensaciones agudas evitables pueden disparar ese gasto hasta en 239 %.

Las cifras dimensionan la urgencia (Fig. 1). La prevalencia nacional de síndrome metabólico ronda el 16,8 % y trepa a 20,7 % en Lima Metropolitana, con una brecha de género llamativa —26,4 % en mujeres frente a 7,2 % en hombres— y valores que llegan al 40,1 % en poblaciones vulnerables como los usuarios de comedores populares [2, 3]. Hay un dato que nos pareció especialmente revelador: el 47,9 % de las personas con peso normal ya son metabólicamente no saludables. Es decir, la balanza no basta para descartar el riesgo, y un tamizaje que solo mire el peso deja fuera a casi la mitad de los afectados.

Frente a ese vacío proponemos **GEMA** (de “Gemelo Metabólico”): un modelo digital del metabolismo de cada persona que aprende de sus datos reales y estima cómo responderá su cuerpo ante distintos hábitos, para devolverle recomendaciones útiles en el momento. La

idea de gemelo digital no es nueva en salud, pero sí hay un hueco concreto que queremos llenar: no encontramos ninguna herramienta de este tipo adaptada al contexto peruano —la dieta de arroz, papa y menú; el perfil del adulto limeño de 20 a 45 años; un módulo hormonal femenino— ni pensada para articularse con SIS y EsSalud.

El resto del artículo está organizado así. La Sección II ubica el trabajo frente a la evidencia existente; la Sección III describe la arquitectura, el ICM, los datos con que entrenamos y los dos modelos; la Sección IV reporta los resultados; la Sección V presenta la aplicación; y la Sección VI discute alcances y limitaciones antes de concluir.

II. TRABAJOS RELACIONADOS

Un gemelo digital en salud es, en esencia, una réplica computacional del metabolismo de una persona que se mantiene al día integrando el sensor de glucosa, los vestibles y los datos clínicos mediante aprendizaje automático. La diabetes es un terreno fértil para este enfoque justamente porque es rico en datos [11]. La referencia obligada es *Twin Health*, cuyo “Whole Body Digital Twin” reportó, en un ensayo controlado, una remisión de diabetes tipo 2 del 71 % al cabo de un año, frente a apenas 2,4 % en la atención estándar [5]. Ese resultado nos sirvió de prueba de que la idea no es solo atractiva en el papel.

La pieza técnica que hace funcionar a estos sistemas es la *respuesta glucémica postprandial individual*: dos personas pueden comer exactamente el mismo plato y registrar picos de glucosa muy distintos. Zeevi *et al.* [4] mostraron que esa respuesta se puede anticipar con *gradient boosting* usando características de la comida y de la persona; es precisamente el enfoque que adoptamos para nuestro Modelo 2. Para el índice resumen nos inspiramos en los *scores* continuos de severidad metabólica, como el MetS-Z [9], que demuestran que es viable condensar varios marcadores en un solo número interpretable. GEMA toma estas ideas, las aterriza al contexto local y las empaqueta en algo que cabe en un teléfono.

III. MATERIALES Y MÉTODOS

Organizamos el proyecto como un *pipeline* reproducible que va desde la captura del dato hasta la pantalla del usuario. La Fig. 2 resume la arquitectura en cuatro capas; este artículo se concentra en la tercera (el motor de IA) y en un MVP de la cuarta.

A. El Índice de Carga Metabólica (ICM)

El ICM es la traducción del estado metabólico a un número de 0 a 100 que cualquiera puede entender. Lo definimos como un promedio ponderado de cinco sub-índices:

$$\text{ICM} = 0,35g + 0,20a + 0,20s + 0,15e + 0,10n, \quad (1)$$

donde $g, a, s, e, n \in [0, 100]$ corresponden a glucosa, actividad, sueño, estrés y nutrición. Los tramos 0–39 (verde), 40–69 (ámbar) y 70–100 (rojo) fijan el color y la expresión del avatar (Fig. 3). Que la glucosa pese más que el resto no es arbitrario: es el marcador que el propio modelo de riesgo señala como el más informativo, según veremos en la Sección IV. El usuario ve este índice en la pantalla principal de la app (Fig. 8b), donde además se desglosa en sus cinco componentes.

B. Generación de la población de entrenamiento

Aquí enfrentamos el obstáculo más evidente del proyecto: todavía no tenemos usuarios reales con CGM, de modo que no hay un dataset propio con el cual entrenar. En lugar de esperar, optamos por generar una población sintética *fisiológicamente plausible*: 6 000 usuarios para el modelo de riesgo y 9 000 eventos de comida para el de pico. La gracia

TABLA II
RELACIONES FISIOLÓGICAS CODIFICADAS EN EL GENERADOR SINTÉTICO

Relación modelada	Fuente
Carga glucémica → principal impulsor del pico	Zeevi 2015 [4]
Caminar tras comer → reduce el pico ~20 %	Reynolds 2016 [6]
Dormir <7 h → resistencia a insulina al día sig.	Spiegel 1999 [7]
HRV baja (estrés) → cortisol eleva la glucosa	NCEP/HPA [1]
Índice TyG → proxy de resistencia a la insulina	Simental 2008 [8]

TABLA III
VARIABLES DE ENTRADA DE LOS DOS MODELOS DE GEMA

Modelo	Variables de entrada (fuente)
M1. Riesgo	CV glucémico, tiempo en rango, pico postprandial (CGM); sueño, pasos, HRV (smartwatch); índice TyG (laboratorio); cintura (perfil)
M2. Pico	Glucosa basal, carbohidratos, índice y carga glucémica (comida); caminata posterior, sueño previo, HRV, hora del día

no está en inventar números al azar, sino en que esos números obedezcan relaciones causales que la literatura ya documentó (Tabla II). Por ejemplo, asignamos a cada usuario un factor latente de “carga metabólica” y a partir de él derivamos sus hábitos y marcadores, de manera que quien duerme poco tienda a mostrar más variabilidad glucémica, y quien camina poco, más cintura. Sobre esa base añadimos ruido individual para que el modelo aprenda patrones y no copias exactas.

Validar el diseño fue tan importante como generarlo. Decidir distribuciones realistas no garantiza que el problema sea aprendible, así que verificamos tres cosas antes de entrenar. Primero, que las clases quedaran efectivamente desbalanceadas, como ocurre en la realidad. Segundo, que ninguna variable “filtrara” la respuesta de forma trivial. Tercero, que la fuente de datos pudiera intercambiarse sin tocar el resto del código: el día que lleguen datos reales del piloto, solo cambia el origen, no el *pipeline*. Este último punto fue una decisión de ingeniería deliberada y, en la práctica, el principal motivo por el que trabajamos con datos sintéticos en esta etapa.

C. Modelo 1: clasificador de riesgo metabólico

El primer modelo responde a una pregunta directa: ¿cómo está el usuario hoy? Lo clasifica en riesgo bajo, moderado o alto y entrega la probabilidad de cada clase, que la app usa para teñir y animar al gemelo. Es un *Random Forest* de 200 árboles que toma el resumen de los últimos 7 días en ocho variables (Tabla III): variabilidad glucémica, tiempo en rango y pico postprandial promedio del CGM; horas de sueño, pasos y HRV del reloj; índice TyG de laboratorio; y circunferencia de cintura del perfil. Elegimos *Random Forest* por tres motivos prácticos: tolera bien el ruido, captura interacciones no lineales sin que tengamos que especificarlas, y —no menos importante para una herramienta de salud— permite explicar en qué se apoya cada decisión [10].

D. Modelo 2: predictor del pico glucémico postprandial

El segundo modelo mira hacia adelante: estima a cuánto subirá la glucosa (~60 min después) si la persona come tal plato. Ese número es el que la app muestra al registrar una comida. Lo resolvimos con un *Gradient Boosting Regressor* de 400 árboles alimentado por ocho variables del evento (Tabla III): glucosa basal, carbohidratos, índice y carga glucémica del plato, minutos de caminata posterior, sueño de la noche previa, HRV y hora del día. Conviene aclarar que este modelo tabular es el *baseline*: replica el método de Zeevi *et al.* [4] y es el que entra al MVP. En producción lo reemplazará una red LSTM que lea la serie completa del CGM de las últimas 12 h [11]; dejamos esa puerta abierta a propósito.




Fig. 2. Arquitectura de GEMA en cuatro capas. El dato nace en los sensores y los autorreportes, se valida y almacena en el backend, alimenta a los dos modelos del gemelo y regresa al usuario convertido en un avatar, un índice de riesgo y recomendaciones. El cumplimiento de la Ley N° 29733 de protección de datos personales se aplica de extremo a extremo.



Fig. 3. Composición del Índice de Carga Metabólica. Cinco sub-índices ponderados se condensan en un solo valor 0–100 que gobierna el estado del gemelo.

TABLA IV
DESEMPEÑO DE LOS MODELOS FRENTE A LAS METAS TÉCNICAS

Modelo / métrica	Resultado	Meta	Estado
M1 — Exactitud (test, $n=1200$)	88,5 %	>85 %	Cumple
M1 — Validación cruzada 5-fold	$87,5 \pm 0,9$ %	—	Cumple
M1 — F1 por clase (bajo/mod./alto)	0,90 / 0,85 / 0,91	—	Cumple
M2 — Error medio absoluto (MAE)	6,3 mg/dL	<15 mg/dL	Cumple
M2 — Coeficiente R^2 (test, $n=1800$)	0,914	—	Cumple

IV. RESULTADOS

Evaluamos ambos modelos sobre conjuntos de prueba que el entrenamiento nunca vio (20 % de los datos). La Tabla IV compara su desempeño con las metas de la guía técnica; el resumen es que las dos quedan holgadamente cubiertas.

A. Clasificación de riesgo

El clasificador acertó el 88,5 % de los casos de prueba y se mantuvo estable en validación cruzada ($87,5 \pm 0,9$ %), con F1 de 0,90, 0,85 y 0,91 para bajo, moderado y alto. Más allá del promedio, lo que nos interesaba era *cómo* se equivoca, y ahí la matriz de confusión (Fig. 4) trae una buena noticia: el modelo nunca confunde un riesgo bajo con uno alto ni viceversa —esas dos celdas son cero—; cuando falla, lo hace entre niveles vecinos, que es el error menos grave para un tamizaje. El análisis de importancia de variables (Fig. 5) refuerza la coherencia clínica del modelo: el tiempo en rango glucémico (29,1 %), la variabilidad de la glucosa (23,5 %) y el pico postprandial (17,3 %) suman casi el 70 % de la decisión. Que los marcadores del CGM manden de esa forma es justo lo que esperábamos, y es la razón empírica detrás del peso de 0,35 que la glucosa recibe en la Ec. (1).

B. Predicción del pico glucémico

El predictor de pico cerró con un error medio absoluto de 6,3 mg/dL y un $R^2 = 0,914$ sobre 1 800 comidas de prueba. Para ponerlo en perspectiva, la guía clínica considera aceptable un error de hasta 15 mg/dL, así que nos quedamos en menos de la mitad de ese margen. La Fig. 6

	Bajo	Moderado	Alto
Bajo	413	42	0
Moderado	48	396	29
Alto	0	19	253
	Bajo	Moderado	Alto
	Clase predicha		

Fig. 4. Matriz de confusión del clasificador sobre 1 200 casos de prueba. La masa se concentra en la diagonal y no hay cruces entre los extremos bajo↔alto.




Fig. 5. Importancia de las variables en el clasificador de riesgo. Los marcadores glucémicos del CGM concentran cerca del 70 % de la decisión.

enfrenta lo predicho con lo observado: la nube sigue de cerca la diagonal y la gran mayoría de los puntos cae dentro de la banda de tolerancia.

C. Del pronóstico a la recomendación

Un buen pronóstico, por sí solo, no cambia hábitos. Por eso lo que de verdad explotamos del Modelo 2 es su capacidad de responder preguntas contrafactuales. El simulador toma una comida concreta, la evalúa bajo varias decisiones posibles y se queda con la que más baja el pico. La Fig. 7 ilustra el caso de un almuerzo muy peruano —arroz con pollo, 78 g de carbohidratos, índice glucémico 72— en alguien que durmió solo 5,7 h. Sin intervenir, el modelo prevé un pico de 164 mg/dL, claramente alto. Caminar 25 min lo baja a 149; cambiar el arroz por quinua, a 150; y hacer las dos cosas juntas lo lleva a 132 mg/dL, ya dentro de rango. De esa comparación nacen, literalmente, los dos consejos que la app le muestra al usuario. Es la diferencia entre decirle “tu glucosa está alta” y decirle “camina 25 minutos y cambia el arroz por quinua”.




Fig. 6. Pico glucémico predicho frente al observado (1 800 comidas de prueba). Casi todos los puntos caen dentro de la banda clínica de ± 15 mg/dL.




Fig. 7. Simulación contrafactual para un mismo almuerzo bajo cuatro decisiones. Quinua más caminata recorta el pico 32 mg/dL, de 164 (alto) a 132 (rango saludable).

V. LA APLICACIÓN (MVP)

El gemelo cobra forma en una aplicación móvil construida con Next.js y React, con 14 pantallas navegables. La Fig. 8 muestra dos de ellas. La de bienvenida (a) plantea desde el inicio el contrato con el usuario: acceso con Google o por correo y, al pie, el aviso de cumplimiento de la Ley N° 29733 y el cifrado AES-256. La pantalla principal (b) es el corazón de la experiencia: presenta el ICM del día —en el ejemplo, 60, “riesgo moderado”— junto al gemelo y al desglose de los cinco sub-índices, cada uno con su valor y su tendencia.

El elemento que mejor comunica el estado de salud no es una cifra sino el propio avatar, que cambia de gesto, color y postura según el ICM (Fig. 9): sonríe y se ve enérgico cuando el riesgo es bajo, se torna neutro cuando es moderado y luce cansado cuando es alto. Apostamos por esta metáfora porque convierte un dato clínico abstracto en una señal emocional que se capta de un vistazo, sin necesidad de interpretar números.

Las demás pantallas acompañan el ciclo completo de uso, agrupadas en cuatro bloques (Tabla V): el *onboarding*, el núcleo de monitoreo diario, el seguimiento a mediano plazo y el puente con el sistema de salud. Dos capacidades ya son reales, no simuladas: el análisis del plato por visión por computador —que estima carbohidratos, índice y carga glucémica desde una foto y alimenta al Modelo 2— y el simulador “¿qué pasaría si...?”, que recalcula el ICM y el pico en vivo al mover los controles. El resto de integraciones de hardware (smartwatch BLE




Fig. 8. Capturas reales del MVP. (a) Bienvenida con login y aviso de privacidad (Ley N° 29733, cifrado AES-256). (b) Panel principal con el ICM del día, el gemelo y los cinco sub-índices.




Fig. 9. El gemelo reacciona en tiempo real al ICM: expresión, color y postura comunican el nivel de riesgo (bajo, moderado, alto) de un solo vistazo.

y sensor CGM) son, por ahora, *mocks* a la espera del piloto.

A. Privacidad y cumplimiento

Tratándose de datos de salud, la privacidad no fue un agregado de última hora sino un requisito de diseño. GEMA se construye para cumplir la Ley N° 29733 de Protección de Datos Personales del Perú: el consentimiento se solicita en la misma pantalla de bienvenida (Fig. 8a), la información viaja cifrada con TLS 1.3 y se almacena con AES-256, y el backend valida que cada lectura caiga dentro de rangos fisiológicos antes de guardarla —lo que, de paso, descarta errores de los sensores. El público al que apuntamos primero son los adultos de 20 a 45 años de Lima Metropolitana con dos o más alteraciones metabólicas, un segmento donde la detección temprana rinde más y que conecta de forma natural con la cobertura de SIS y EsSalud.

VI. DISCUSIÓN Y LIMITACIONES

Conviene ser claros sobre el alcance de estos resultados. La limitación de fondo es que los modelos se entrenaron con datos sintéticos: las métricas demuestran que el *pipeline* funciona y que las relaciones fisiológicas asumidas son aprendibles, pero no equivalen todavía a una validación clínica. Un riesgo asociado es que el modelo aprenda las reglas que nosotros mismos codificamos en el generador; lo mitigamos con ruido individual y comprobaciones de variedad, aunque la prueba definitiva solo llegará con datos reales.

TABLA V
LAS 14 PANTALLAS DEL MVP, AGRUPADAS POR ETAPA DE USO

Bloque	Pantallas
Onboarding	Bienvenida y login, crear gemelo (cámara), personalizar gemelo, procesando
Núcleo	Panel principal (ICM), mi gemelo + simulador, registro diario de comida / sueño / estrés
Seguimiento	Progreso e historial, proyección de riesgo a 5 años, recomendaciones, alertas, detalle de sub-índice
Clínico	Reporte para el médico, perfil del usuario

El plan para cerrar esa brecha tiene tres pasos. El primero es un piloto con usuarios reales y dos semanas de calibración por persona, que permitiría afinar el gemelo de forma individual. El segundo es sustituir el Gradient Boosting por la red LSTM prevista, capaz de aprovechar la dinámica temporal del CGM en lugar de un resumen tabular. El tercero es preentrenar el modelo base con datasets poblacionales de referencia como NHANES y ENDES, y reentrenar de forma periódica. Quedan también frentes abiertos que excedían este entregable: el módulo hormonal femenino, la integración formal con SIS y EsSalud, y un estudio de generalización fuera de Lima.

Aun con estas salvedades, el potencial de impacto justifica seguir adelante. En el país, entre el 40 % y el 60 % de las amputaciones no traumáticas se deben a la diabetes, y la mortalidad por esta causa creció más de 50 % en dos décadas; muchos pacientes debutan directamente con un infarto. Una herramienta que adelante la detección y sostenga el seguimiento ataca justo el tramo del problema donde hoy no hay nadie acompañando al paciente. No es casual que el mercado de gemelos digitales en salud, valorado en USD 4,92 mil millones en 2024, se proyecte hacia los USD 21,3 mil millones para 2032: la evidencia y la demanda apuntan en la misma dirección.

VII. CONCLUSIONES

- El clasificador de riesgo alcanzó 88,5 % de exactitud (87,5 % en validación cruzada), por encima de la meta de 85 %, y —lo más relevante en salud— no comete el error grave de confundir riesgo bajo con alto. Sus decisiones se apoyan en marcadores glucémicos del CGM, que reúnen cerca del 70 % de la importancia.
- El predictor de pico erró en promedio 6,3 mg/dL ($R^2 = 0,91$), menos de la mitad del margen clínico de 15 mg/dL, y habilita un simulador que cuantifica el efecto de caminar o de cambiar un alimento.

- El ICM y el avatar logran traducir un estado clínico complejo en una señal que cualquiera entiende, y el MVP de 14 pantallas demuestra que la experiencia de usuario completa es viable hoy.
- En conjunto, GEMA ataca la causa de fondo —la falta de detección temprana y de seguimiento— con una herramienta de bajo costo y pensada para el contexto peruano, y deja un *pipeline* reproducible listo para recibir datos reales en la fase piloto.

RECONOCIMIENTOS

Agradecemos a los docentes de la Facultad de Ingeniería Industrial y de Sistemas de la UNI por su retroalimentación durante el desarrollo del proyecto. El código del modelo predictivo y de la aplicación se entrega junto a este informe.

REFERENCIAS

- [1] National Cholesterol Education Program (NCEP-ATP III) and AHA/NHLBI, “Diagnosis and management of the metabolic syndrome,” *Circulation*, vol. 112, no. 17, pp. 2735–2752, 2005.
- [2] Instituto Nacional de Estadística e Informática y SciELO Perú, “Prevalencia de síndrome metabólico en adultos peruanos (criterio ATP III),” *Rev. Peruana de Medicina Experimental y Salud Pública*, 2018.
- [3] L. Pajuelo *et al.*, “Síndrome metabólico en usuarios de comedores populares de Lima,” *Rev. Peruana de Medicina Experimental y Salud Pública*, 2019.
- [4] D. Zeevi *et al.*, “Personalized nutrition by prediction of glycemic responses,” *Cell*, vol. 163, no. 5, pp. 1079–1094, 2015.
- [5] P. Shamanna *et al.*, “Reducing HbA1c in type 2 diabetes using digital twin technology-enabled precision nutrition,” *Diabetes Therapy*, vol. 11, pp. 2703–2714, 2020.
- [6] A. N. Reynolds *et al.*, “Advice to walk after meals is more effective for lowering postprandial glycaemia,” *Diabetologia*, vol. 59, pp. 2572–2578, 2016.
- [7] K. Spiegel, R. Leproult, and E. Van Cauter, “Impact of sleep debt on metabolic and endocrine function,” *The Lancet*, vol. 354, pp. 1435–1439, 1999.
- [8] L. E. Simental-Mendía *et al.*, “The product of fasting glucose and triglycerides as surrogate for insulin resistance,” *Metab. Syndr. Relat. Disord.*, vol. 6, no. 4, pp. 299–304, 2008.
- [9] M. J. Gurka *et al.*, “An examination of sex and racial/ethnic differences in the metabolic syndrome severity score,” *Metabolism*, vol. 63, no. 2, pp. 218–225, 2014.
- [10] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [11] S. Oviedo *et al.*, “A review of personalized blood glucose prediction strategies for T1DM patients,” *Int. J. Numer. Method Biomed. Eng.*, vol. 33, no. 6, 2017.
- [12] International Diabetes Federation, *IDF Diabetes Atlas*, 10th ed., Brussels, Belgium, 2024. [Online]. Available: <https://diabetesatlas.org/>
- [13] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*, 2nd ed. Sebastopol, CA: O’Reilly, 2019.